

Comportamento adaptativo de inimigos em jogos digitais: Reinforcement learning

Gustavo Luigi Chao Pinotti

10419700

Pedro Henrique Lanfredi Moreiras

10441998

3) Resumo

Este artigo irá tratar sobre o uso de inteligência artificial, mais especificamente o reinforcement learning na criação de um inimigo em um jogo capaz de decidir seu estado, desviar de projéteis, mira que acompanha um personagem em movimento e escolher o tipo correto de projétil para utilizar de forma autônoma.

4) Introdução

Nos últimos anos, os avanços da tecnologia vem se tornando algo cada vez mais frequente, avanços que levam inúmeros meses para acontecer agora acontecem toda semana. Uma vertente que vem se tornando mais presente e eficiente nos últimos anos foi a inteligência artificial(IA).

Com estes avanços inúmeras indústrias no mercado vem se beneficiando, uma delas é muito popular com os brasileiros é a indústrias dos jogos já que segundo Tadeu e Tortella (2022), “74,5% de sua população que diz jogar games”. A IA vem possibilitando aos desenvolvedores de jogos criar inimigos cada vez mais complexos capazes de pensar como agir da melhor forma possível e até se adaptar com o desenvolver da narrativa ou combate.

A partir desse artigo, temos como objetivo desenvolver uma maneira para ajudar no desenvolvimento da lógica de inimigos autônomos para jogos digitais, com o intuito de facilitar no treinamento e na implementação das lógicas, durante o período de desenvolvimento de um jogo.

Diante disso, esse artigo tem como proposta demonstrar como executar um paradigma de machine learning (ML), o reinforcement learning (RL) e utilizar o algoritmo de Q-learning (QL) para fazer um agente autônomo capaz de tomar decisões próprias em um contexto de um jogo. Além disso, não foi enxergada a necessidade na utilização de um dataset, devido a

customização que será realizada para a implementação do jogo que será desenvolvido, e também para os futuros usuários que forem utilizar esse projeto como treino de lógica dos seus próprios inimigos.

Por fim, como opções que selecionamos para a realização desse projeto, decidimos fazer a escolha de utilização de algumas ferramentas. Dentre elas, pretendemos utilizar o Q-Learning, como a estrutura de algoritmo, o *Gymnasium*, da *OpenAI*, com o intuito de ter um ambiente e bibliotecas para o treinamento dos algoritmos, e o *RL Baseline3 Zoo*, como *framework* para proporcionar ferramentas para a análise dos algoritmos a serem realizados.

5) Fundamentação Teórica (Resumida) ou Revisão da Literatura

5.1. Introdução ao Aprendizado de Máquina

Um dos grandes objetivos da computação é a criação de uma máquina que tivesse a capacidade de ter algo próximo de uma inteligência própria, para atingir esse objetivo foi criado uma nova área de pesquisa o Aprendizado de Máquinas, que segundo *Samuel (1959, citado por PETRIK, 2017)* “*Machine Learning é o campo de estudo que possibilita computadores terem a habilidade de aprender sem ter sido explicitamente programada para fazer*”.

5.2. Reinforcement Learning (Aprendizado por Reforço)

Dentro do paradigma de aprendizado de máquinas existem diversas subcategorias, uma delas sendo o *Reinforcement Learning* que segundo *KANERVISTO et al, 2022, p. 185* “*(RL) é a forma de aprendizado de máquina que foi construído na ideia de aprender por iterações e aprender lentamente por sinais de recompensa numérica*”. Isto é ótimo para desenvolver uma inteligência artificial, flexível capaz de se adaptar a um cenário e não apenas chegar no resultado final. O funcionamento do *RL* foi exemplificado por *SUTTON; BARTO, 2018, seção 1.1* “*RL providencia um framework para o agente para aprender por tentativa e erro enquanto tenta diferentes ações e avaliando seus resultados*”.

5.3. Algoritmo Q-Learning

Levando em consideração o contexto de RL existem diversos algoritmos para atingir este objetivo, um deles sendo o Q-learning que segundo *HASSELT et al, 2016, p36* “*Q-learning aprende o valor de uma ação e então a utiliza para criar uma política. Já que o valor da ação define o tamanho do retorno associado a cada ação, escolher a ação com o maior valor retorna o maior retorno.*”. O que é algo extremamente importante para o personagem de um jogo já que ele irá tomar as ações mais coerentes com a situação.

5.4. Trabalhos Relacionados

Um trabalho relacionado que é interessante de nos levar em consideração é o do *KANERVISTO et al, 2022, p. 185* onde eles tratam de técnicas que podem agregar no treinamento de uma IA com RL sendo elas Aprendizado de Currículo Manual, Ações modificadas entre outras. Outro trabalho que pode ser utilizado como base é o projeto de (*KANERVISTO; HAUTAMÄKI, 2019*). onde eles conseguiram criar um personagem autônomo, capaz de seguir regras e ter um nível considerável de habilidade, mesmo que ainda o personagem não consiga derrotar o jogador.

6) Metodologia e Resultados Esperados:

Dando um maior contexto para o nosso projeto, estamos desenvolvendo um jogo na plataforma Unity, porém como um dos elemento para esse jogo, pretendemos adicionar inimigos que agem de forma autônoma, e que consigam tomar decisões baseadas no contexto do cenário e sempre se adaptando sobre ele, e realizando a melhor ação para ele.

Diante disso, para alcançarmos esse objetivo, planejamos algumas formas que podem ser utilizadas para o desenvolvimento desses inimigos. Uma das possibilidades seria fazer a utilização de bibliotecas voltadas ao aprendizado por *reinforcement learning* que oferecem ambientes padronizados para experimentação e comparação de algoritmos, como é o caso do *Gymnasium* da *OpenAI* (*BROCKMAN et al., 2016*). A partir dele, é possível ter o acesso a bibliotecas que buscam realizar a padronização da interação entre os agentes e ambientes, facilitando o desenvolvimento e a comparação dos algoritmos (*TOWERS et al., 2024*). Tendo o contexto do nosso projeto, através dele, será possível realizar os treinamentos das métricas para o inimigo do jogo, ou seja, para qual lado mexer, se aproximar ou afastar do jogador, desviar, escolher o projétil, entre outras decisões.

Tendo o ambiente definido com o uso do *Gymnasium*, a próxima etapa consiste no algoritmo que será utilizado para o devido treinamento. O *RL BaseLine3 Zoo* é um *Framework* que fornece ferramentas, *scripts* e configurações otimizadas para treinamento e avaliação de algoritmos em *reinforcement learning* (*RAFFIN, 2020*). Baseado em sua definição, e na etapa do projeto, faremos uso do *RL BaseLine3 Zoo*, junto do *Gymnasium*, com o objetivo de adquirir uma análise dos

algoritmos que serão utilizados para o treinamento, para que seja possível obtermos a lógica de um inimigo balanceado, ou seja, que não seja extremamente avançado, porém nem muito simples, limitando os extremos de algo muito fácil ou muito difícil.

O agente utiliza do *RL* com os seguintes parâmetros de aprendizado: taxa de aprendizado 0,0004, número de passos 2048 e tamanho de lote 64. O agente foi treinado em 500.000 passos. Dentro do ambiente a ia teve que aprender a escolher uma de 4 ações: utilizar o tiro de fogo, tiro de gelo, se aproximar ou desviar, para a lógica do desvio ela funciona com um balanceamento para evitar que o inimigo chegasse muito perto ou muito longe do personagem, já o tiro havia um que era mais fácil de se acertar porém mais fraco e o outro difícil porém forte. Devido ao Gymnasium gerar um modelo .zip em python, que a unity não consegue manipular foi feito uma conversão do tipo do arquivo para .onnx .

7) Resultados Parciais

A inteligência artificial como ferramenta traz diversas vantagens para a sociedade como avanços significativos na medicina e a democratização do conhecimento, ainda assim ela pode acabar trazendo diversos malefícios, como a propagação de informações falsas (fake news) e o “roubo” de propriedade intelectual já que a coleta dados para montar os datasets não possuem muita regulação. Por conta desses problemas é nosso dever como desenvolvedor garantir que haja uma transparência em relação ao nosso produto e as ferramentas / modelos utilizados.

Diante desses fatores, pretendemos alcançar o objetivo de nosso projeto da forma mais ética possível, utilizando recursos que não contenham a proteção de direitos autorais, além da verificação dos dados que serão utilizados para o desenvolvimento e treino do nosso projeto, com objetivo de gerar resultados mais coerentes possíveis.

Tendo isso em mente, nós pretendemos criar um inimigo para um jogo utilizando RL a partir de um modelo feito no Gymnasium e treinado no ambiente do RL Baseline 3 Zoo , onde o npc é capaz de decidir o seu estado se ele ataca / foge, qual tipo correto de projétil usar, ter uma mira que acompanha um personagem em movimento e desviar de projéteis de forma autônoma, sem que ele fique muito bom a ponto de ser impossível que o jogador faça algo contra e não tenha pouca inteligência não sendo capaz de realizar as tarefas de uma boa forma.

Após o treinamento do modelo ele percorreu 510,760 passos, uma variância de 0.571 e uma loss de 843 isso significa que o nosso modelo ainda não conseguiu aprender muito bem o cenário e apresenta sinais de underfit uma parte por conta da natureza um pouco aleatória de algumas partes do ambiente porém ele ainda apresenta pontos a melhorar.

Link de acesso ao GitHub:

https://github.com/7uigi/Inteligencia_Artificial_em_Problema_Real-

Link de acesso ao Vídeo no Youtube:

https://www.youtube.com/watch?v=yhMSd_hae4c

8) Referências: obtidas por pesquisas e citadas dentro do texto do projeto

BROCKMAN, G. et al. *OpenAI Gym*. 2016. Disponível em: <https://arxiv.org/abs/1606.01540>. Acesso em: 28 maio 2026.

FARAMA FOUNDATION. *Gymnasium Documentation*. Disponível em: <https://gymnasium.farama.org/>.

KANERVISTO, A.; HAUTAMÄKI, V. ToriLLE: Learning Environment for Hand-to-Hand Combat. In: *IEEE Conference on Games*, 2019, London, UK. Anais... London: IEEE, 2019. p. 1–8. ©2019 IEEE.

KANERVISTO, A.; SCHELLER, C.; SCHRANER, Y.; HAUTAMÄKI, V. Distilling Reinforcement Learning Tricks for Video Games. In: *IEEE Conference on Games*, 2021, Virtual. Proceedings... [s.l.: s.n.], 2021.

PETRIK, Marek. *Introduction to Machine Learning*. 26 jan. 2017.

RAFFIN, Antonin. *RL Baselines3 Zoo*. 2020. Disponível em: <https://github.com/DLR-RM/rl-baselines3-zoo>.

SAMUEL, Arthur L. Machine learning. *The Technology Review*, v. 62, n. 1, p. 42–45, 1959.

SUTTON, Richard S.; BARTO, Andrew G. *Reinforcement learning: an introduction*. 2. ed. Cambridge: MIT Press, 2018.

VAN HASSELT, H.; GUEZ, A.; SILVER, D. Deep reinforcement learning with double Q-learning. In: *AAAI Conference on Artificial Intelligence*, 2016.

VINÍCIUS TADEU; TIAGO TORTELLA. Público gamer cresce e 3 em cada 4 brasileiros consomem jogos eletrônicos.

CNN Brasil, 2022. Disponível em: <https://www.cnnbrasil.com.br/tecnologia/publico-gamer-cresce-e-3-em-cada-4-brasileiros-consomem-jogos-eletronicos/>.

